



UNIVERSIDAD DE EL SALVADOR
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

DOCTOR MAÍZ

Clasificación de enfermedades y deficiencias
nutricionales en hojas de maíz

INFORME DE ETAPA 2

Optimización, evaluación final y prototipo funcional

Josias Abner Rivas Fuentes	RF20010
David Alejandro Deras Cerros	DC19019
Elmer Edenilson Rosales Molina	RM20001

San Salvador, El Salvador
Septiembre de 2026

Resumen

Esta segunda etapa parte del clasificador obtenido en la etapa anterior y se concentra en los problemas que quedaron abiertos: el bajo rendimiento de potasio, el desbalance, el sesgo laboratorio/campo, la selección del modelo y una evaluación final que no reutilizara el test histórico. Se reconstruyó la publicación ampliada del dataset, se verificaron 33 437 archivos y se eliminaron cuatro duplicados exactos. El corpus definitivo contiene 33 433 imágenes de nueve clases, con un holdout nuevo de 5 015 fotografías congelado antes de modelar y fingerprint `c44de0783d3c3f88ef6151eaa75536d1020f5b208327419c4cb7f3ac459d3892`.

Por ausencia de GPU, los experimentos nuevos utilizaron backbones ImageNet congelados y una cabeza logística entrenada sobre sus embeddings; no se presentan como fine-tuning end-to-end. Optuna ejecutó 30 trials sobre EfficientNet-B0 y podó 13. La mejor configuración elevó el macro-F1 de validación de la cabeza baseline de 0.7799 a 0.8887, principalmente al usar balanceo por raíz cuadrada, una tasa menor y penalización L2. EfficientNet-B0 superó a ShuffleNetV2-x1.0, MobileNetV3 Small y FastViT-T8 como modelo individual. Los errores fueron suficientemente distintos para que el weighted soft voting mejorara hasta 0.9202 en validación, con pesos aprendidos sin consultar el holdout.

En cinco folds, el ensemble obtuvo macro-F1 medio de 0.9097 y desviación 0.0090. La evaluación única del holdout produjo 0.9537 de accuracy, 0.9012 de precision macro, 0.9092 de recall macro, 0.9035 de macro-F1 y 0.9537 de F1 ponderado. Potasio mejoró de forma orientativa desde el F1 histórico 0.62 hasta 0.6706, pero siguió siendo la clase más débil: 28 de sus 36 errores terminaron en nitrógeno. Fairness encontró las mayores brechas por clase (0.3206 de F1) y fuente (0.3151); además, roya obtuvo recall 1.0 en 322 imágenes de laboratorio y 0.3125 en solo 16 de campo, una señal importante aunque de soporte pequeño.

Grad-CAM y LIME se aplicaron a casos finales, incluidos un error de alta confianza y una deficiencia nutricional. La demo ejecutable genera Top-3, confianza, latencia y advertencia sobre una imagen real. También se verificó la aplicación React Native con EfficientNet-Lite0 TFLite, inferencia offline y rechazo fuera de dominio: typecheck y 276 pruebas aprobaron. El endpoint y el APK no estuvieron disponibles en la comprobación final, por lo que el prototipo es funcional e integrado, pero no recibe puntuación completa de despliegue público.

Palabras clave: clasificación foliar, maíz, Optuna, ensemble, validación cruzada, fairness, interpretabilidad, inferencia móvil.

Índice

Resumen	I
1. Introducción	1
1.1. Punto de partida de la Etapa 1	1
1.2. Alcance de la Etapa 2	1
2. Objetivos	2
2.1. Objetivo general	2
2.2. Objetivos específicos	2
3. Dataset actualizado y protocolo experimental	3
3.1. Qué cambió desde la Etapa 1	3
3.2. Composición y procedencia	3
3.3. Prevención de fugas y división	4
3.4. Preprocesamiento y métricas	5
4. Optimización del clasificador	5
4.1. Baseline de referencia	5
4.2. Espacio de hiperparámetros	5
4.3. Resultados del tuning	6
5. Modelos avanzados	8
5.1. Arquitecturas evaluadas	8
5.2. Comparación experimental	8
6. Ensemble	9
6.1. Complementariedad antes de combinar	9
6.2. Resultado de la combinación	10
7. Validación cruzada	11
7.1. Diseño	11
8. Evaluación final	12
8.1. Apertura única del holdout	12
8.2. Resultados globales y por clase	13
8.3. Matriz de confusión	14
8.4. Etapa 1 frente a Etapa 2	14
9. Análisis de errores	15

9.1. Deficiencias de nitrógeno, fósforo y potasio	15
9.2. Potasio: el cuello de botella anterior	15
9.3. Mancha gris y tizón norteño	15
9.4. Errores de alta confianza	16
10. Interpretabilidad	16
11. Sesgos y fairness	19
11.1. Laboratorio frente a campo	19
11.2. Fuente, resolución, nitidez y clases pequeñas	20
12. Consideraciones éticas	20
12.1. Confianza y comunicación del resultado	21
12.2. Errores con costos distintos	21
12.3. Datos, ubicación y trazabilidad	21
12.4. Supervisión y salida segura	22
13. Prototipo funcional	22
13.1. Arquitectura verificada	22
13.2. Comprobación ejecutable	22
13.3. Qué modelo está desplegado	23
14. Impacto social	24
14.1. Una herramienta de primera observación	24
14.2. Productores y extensionistas	24
14.3. Beneficio posible y evidencia disponible	24
14.4. Riesgos de exclusión	25
14.5. Condiciones para uso real	25
15. Recomendaciones de política pública	25
16. Limitaciones	26
17. Conclusiones	27
17.1. Cumplimiento de la rúbrica	28

Índice de figuras

1.	Distribución del corpus único por clase y entorno. Las deficiencias ampliaron su soporte, pero siguen siendo minoritarias y exclusivamente de campo en los metadatos disponibles.	4
2.	Macro-F1 de los trials completos y mejor valor acumulado. La línea discontinua corresponde al baseline de la cabeza, no al modelo histórico.	6
3.	Importancia relativa calculada por Optuna dentro del espacio explorado. Una importancia baja no prueba que el hiperparámetro sea inútil fuera de esos rangos.	7
4.	Relación entre macro-F1, tamaño FP32 y latencia del backbone. El color de cada punto corresponde a la latencia CPU.	9
5.	Cambio de macro-F1 al combinar los cuatro modelos. La escala se acota para que una diferencia pequeña no desaparezca visualmente.	10
6.	Macro-F1 por fold y media de la configuración seleccionada.	12
7.	Rendimiento final por clase. El soporte desigual no cambia el peso de cada barra en macro-F1.	13
8.	Matriz final en conteos y normalizada por clase real. La segunda vista permite leer clases pequeñas sin que desaparezcan detrás de la clase sana.	14
9.	Casos del holdout y mapas Grad-CAM del método final. El color rojo marca mayor activación relativa dentro de cada imagen.	17
10.	Imagen final seleccionada y explicación local LIME. Los bordes corresponden a segmentos perturbados, no a una segmentación agronómica de la lesión.	18
11.	A la izquierda, macro métricas globales de grupos con composición de clases distinta; a la derecha, recall dentro de las clases presentes en ambos entornos.	19
12.	Flujo real implementado en la aplicación móvil. La API participa en autenticación, sincronización y actualización; la inferencia ocurre en el dispositivo.	22
13.	Captura de la demo de Etapa 2: entrada real y salida producida por el pipeline final. La latencia corresponde a CPU de escritorio y no se presenta como benchmark Android.	23

Índice de cuadros

1.	Composición por clase antes y después de la ampliación. La fuente es el manifiesto generado, no una transcripción manual.	3
2.	Configuración del baseline interno y combinación seleccionada por Optuna.	6
3.	Cinco mejores trials completos según macro-F1 de validación.	7
4.	Efecto observado del tuning sobre la misma división y backbone.	7
5.	Backbones evaluados con la misma cabeza optimizada. MB representa el tamaño FP32 estimado de parámetros del backbone; ms es la mediana de 30 inferencias de una imagen en CPU.	8
6.	Mejor componente individual frente a los dos ensembles en validación.	10
7.	Resultados de cinco folds, media y desviación estándar muestral.	11
8.	Métricas obtenidas en la única evaluación del holdout.	13
9.	Precision, recall y F1 finales para las nueve clases.	13
10.	Referencias de ambas etapas. Accuracy y macro-F1 no son una comparación controlada porque cambiaron corpus, división y entrenamiento.	14
11.	Diferencia entre el mayor y menor valor observado dentro de cada dimensión. Los gaps son descriptivos y no llevan signo.	19
12.	Puntuación final respaldada por artefactos reproducibles.	29

1. Introducción

1.1. Punto de partida de la Etapa 1

La primera etapa dejó un resultado favorable, pero también un problema bastante claro. Los tres modelos ligeros superaron la meta de macro-F1 de 0.85: EfficientNet-B0 alcanzó 0.9146, ShuffleNetV2-x1.0 obtuvo 0.9030 y EfficientNet-Lite0 llegó a 0.8951. La diferencia entre ellos no estaba tanto en reconocer roya, hojas sanas o necrosis letal, sino en las clases con menos ejemplos. `potassium_deficiency` tenía solamente 266 imágenes y su F1 bajó hasta 0.62 con EfficientNet-B0, 0.54 con ShuffleNet y 0.49 con EfficientNet-Lite0. El modelo podía acertar casi siempre en el conjunto completo y, al mismo tiempo, fallar justo en la clase que más necesitaba mejorar.

La matriz de confusión de aquella etapa mostró que las deficiencias de nitrógeno, fósforo y potasio compartían parte de sus errores. También aparecía una confusión menor entre mancha gris y tizón norteño. Las explicaciones LIME y Grad-CAM aportaron otra advertencia: a veces la red miraba la hoja y aun así se equivocaba, pero en imágenes de laboratorio también podía aprovechar un fondo uniforme que no estaría presente en una parcela. La confianza alta tampoco garantizaba una decisión correcta. Esos hallazgos hicieron insuficiente limitarse a entrenar más épocas o escoger el mayor valor de accuracy.

Había además un problema de evaluación. El conjunto llamado *test* había sido consultado durante comparaciones, exportaciones y verificaciones posteriores. Sus métricas siguen siendo útiles como registro histórico, pero ya no representan una prueba ciega. Presentarlas otra vez como resultado final habría dado una precisión metodológica que el experimento no tenía.

1.2. Alcance de la Etapa 2

La segunda etapa responde a esos puntos con un protocolo nuevo. Primero se reconstruyó el corpus desde la publicación completa, se verificó cada archivo y se retiraron duplicados exactos antes de dividir. Luego se congeló un holdout nuevo de 5 015 imágenes, sin emplearlo para elegir arquitectura, hiperparámetros ni pesos del ensemble. La selección trabajó únicamente con entrenamiento y validación; el holdout se abrió una vez al final.

La máquina disponible no expuso una GPU CUDA. Para no reemplazar un experimento real por cifras estimadas, se congelaron backbones preentrenados en ImageNet y se optimizó sobre sus embeddings una cabeza lineal de pérdida logística. Esto no equivale al ajuste fino *end-to-end* empleado en la Etapa 1. Sí permite comparar cuatro representaciones modernas sobre las 33 433 imágenes únicas, ejecutar 30 trials de Optuna, probar soft voting, repetir cinco folds y evaluar el holdout completo en CPU. La restricción cambia la pregunta experimental: se mide qué tan separables son las nueve clases con cada representación preentrenada y una cabeza común optimizada. El informe conserva esa distinción cada vez que compara con el baseline histórico.

También se revisó el producto que rodea al clasificador. La aplicación móvil captura o selecciona una foto, ejecuta un modelo TFLite local, calcula confianza y rechazo fuera de dominio, guarda el diagnóstico sin depender de conectividad y permite sincronizar correcciones. Su modelo embarcado pertenece a la línea histórica EfficientNet-Lite0; no se sustituyó silenciosamente por el modelo experimental de esta etapa. La demo incluida aquí ejecuta la selección de Etapa 2 sobre una

imagen real y deja una salida reproducible, mientras la inspección de la aplicación confirma que existe una ruta móvil completa.

El objetivo no fue acumular arquitecturas. EfficientNet-B0 y ShuffleNet continuaron por su papel en la etapa anterior; MobileNetV3 Small añadió una alternativa diseñada para dispositivos; FastViT-T8 permitió contrastar una arquitectura híbrida reciente. EfficientNet-B4, GhostNetV2 y otros nombres registrados en el código no aparecen como resultados porque no tuvieron una corrida completa en este protocolo. Separar lo implementado de lo evaluado evita convertir el catálogo de modelos en evidencia que no existe.

La lectura final se concentra en cambios observables: cuánto aportó el tuning, si los modelos cometieron errores distintos, si el ensemble justificó su costo, qué variación hubo entre folds, qué ocurrió con potasio y qué brechas aparecieron entre clases, fuentes, resolución, nitidez y entornos de captura. La última parte traslada esos hallazgos a decisiones de uso. Doctor Maíz puede orientar una inspección; no identifica con certeza una causa agronómica ni prescribe por sí solo una aplicación de insumos.

2. Objetivos

2.1. Objetivo general

Optimizar y evaluar el clasificador de Doctor Maíz sobre el corpus actualizado, con un protocolo reproducible que permita seleccionar una alternativa experimental, medir su comportamiento por clase y condición de captura, y comprobar su integración en un prototipo de diagnóstico asistido.

2.2. Objetivos específicos

1. Reconstruir el dataset definitivo de la etapa, validar sus archivos, eliminar duplicados exactos y congelar una división que mantenga separado el holdout final.
2. Optimizar una cabeza clasificadora sobre EfficientNet-B0 mediante búsqueda TPE y pruning con Optuna, usando macro-F1 de validación como función objetivo y sin consultar el holdout.
3. Comparar EfficientNet-B0, ShuffleNetV2-x1.0, MobileNetV3 Small y FastViT-T8 bajo el mismo preprocesamiento, partición y configuración de cabeza, incluyendo calidad, cantidad de parámetros y latencia CPU del backbone.
4. Medir complementariedad de errores y contrastar el mejor modelo individual con soft voting uniforme y ponderado. Los pesos deben aprenderse únicamente en validación.
5. Estimar la estabilidad de la selección con cinco folds estratificados por clase y entorno, y efectuar una sola evaluación sobre el holdout congelado con métricas globales y por clase.
6. Revisar el principal cuello de botella de la Etapa 1, `potassium_deficiency`, cuantificando sus confusiones con nitrógeno, fósforo y las demás categorías.
7. Explicar casos finales con Grad-CAM y LIME, y describir brechas de precision, recall y F1 asociadas con clase, laboratorio/campo, fuente, resolución y nitidez.
8. Verificar el flujo real de la aplicación móvil y producir una demo ejecutable que muestre entrada, preprocesamiento, Top-3, confianza, latencia y advertencia de uso.
9. Traducir las limitaciones encontradas en condiciones de uso, recomendaciones para extensionistas y propuestas concretas de política pública, sin presentar beneficios no medidos.

Estos objetivos combinan tres niveles que en la primera etapa todavía estaban separados: calidad estadística, comportamiento bajo condiciones distintas y operación dentro de una herramienta usable. Una mejora pequeña en macro-F1 no compensa una caída fuerte en campo; del mismo modo, una aplicación bien diseñada no corrige una clase minoritaria mal reconocida. La selección final se lee con las tres dimensiones.

3. Dataset actualizado y protocolo experimental

3.1. Qué cambió desde la Etapa 1

La Etapa 1 trabajó con 31 622 imágenes. Después se añadieron ejemplos a las clases que habían quedado más cortas: mancha gris y las tres deficiencias nutricionales. La publicación completa consultada para esta etapa contenía 33 437 archivos distribuidos en nueve clases [5]. Todos se abrieron, se normalizó su orientación EXIF y se calculó SHA-256, resolución y varianza del Laplaciano como indicador descriptivo de nitidez. No hubo imágenes ilegibles. Cuatro archivos de hojas sanas repetían exactamente el contenido de otro archivo y se eliminaron antes de dividir. El corpus experimental quedó en 33 433 imágenes únicas.

Esta secuencia explica cifras que antes podían parecer contradictorias. 31 622 corresponde al corpus de la Etapa 1; 33 437 es el número de archivos de la publicación ampliada; 33 433 es el total utilizado aquí después de la deduplicación. La cifra 33 438 que aparecía en una versión de la auditoría no coincidió con el dataset descargado ni con su manifiesto y por eso no se conservó como resultado.

Cuadro 1: Composición por clase antes y después de la ampliación. La fuente es el manifiesto generado, no una transcripción manual.

Clase	Etapa 1	Etapa 2	Cambio
Roya común	2 256	2 256	+0
Gusano cogollero	4 857	4 857	+0
Mancha gris	1 119	1 930	+811
Sana	8 744	8 740	-4
Necrosis letal	6 415	6 415	+0
Def. nitrógeno	523	846	+323
Tizón norteño	6 830	6 830	+0
Def. fósforo	612	938	+326
Def. potasio	266	621	+355
Total	31 622	33 433	+1811

El incremento no fue uniforme. Potasio pasó de 266 a 621 imágenes y fósforo de 612 a 938; nitrógeno llegó a 846. Mancha gris recibió la mayor ampliación absoluta entre las clases problemáticas, de 1 119 a 1 930. Aun así, la clase sana conserva 8 740 imágenes, más de catorce veces el soporte de potasio. La ampliación reduce el extremo del desbalance, pero no lo elimina.

3.2. Composición y procedencia

El manifiesto conserva catorce identificadores de fuente obtenidos del nombre versionado de cada archivo. Las colecciones más grandes son `maize_africa`, `multi_desease`, `maize_desease_v1.1`,

`corn_leaf_roboflow` y `cropdg`. No existe un identificador de finca, municipio, dispositivo o campaña de captura. Por eso `nfuentez` permite detectar diferencias entre colecciones, pero no medir generalización geográfica en El Salvador.

La etiqueta de entorno separa 3 551 imágenes de laboratorio y 29 882 de campo. Su distribución está muy lejos de ser factorial: roya común concentra 2 150 imágenes de laboratorio y 106 de campo; mancha gris tiene 513 y 1 417; tizón norteño 888 y 5 942. Las otras seis clases no poseen ejemplos de laboratorio. Esta asimetría importa más que el total global. Si el grupo de laboratorio obtiene otro F1, la diferencia puede deberse tanto al fondo como a las clases que lo componen.




Figura 1: Distribución del corpus único por clase y entorno. Las deficiencias ampliaron su soporte, pero siguen siendo minoritarias y exclusivamente de campo en los metadatos disponibles.

La Figura 1 deja ver dos riesgos. El primero es el peso de la clase sana y de necrosis letal frente a las deficiencias. El segundo es que `nlaboratorioz` funciona casi como una pista de clase. Esto impide interpretar una diferencia global laboratorio/campo como efecto puro del entorno y obliga a acompañarla con comparaciones dentro de las tres clases que sí aparecen en ambos grupos.

3.3. Prevención de fugas y división

La deduplicación se hizo antes del muestreo. Cada fila contiene ruta relativa, clase, índice de clase, entorno, fuente, ancho, alto, megapíxeles, indicador de blur y SHA-256. El fingerprint del conjunto completo se calculó ordenando las rutas y concatenando ruta, clase, entorno y hash. El valor resultante es:

`c44de0783d3c3f88ef6151eaa75536d1020f5b208327419c4cb7f3ac459d3892`

Se reservaron 5 015 imágenes (15 %) como holdout con semilla 4202. El 85 % restante se dividió en 23 403 imágenes de entrenamiento y 5 015 de validación, utilizando semilla 42. Ambos cortes se estratificaron por la combinación clase-entorno. El archivo `holdout.lock.json` se creó antes de

extraer características y guarda el fingerprint, el hash del CSV de holdout y la regla de no consultar sus etiquetas durante selección.

El conjunto histórico llamado test no se reutilizó como prueba final. Esa decisión sacrifica comparabilidad directa con la Etapa 1, pero recupera una interpretación limpia: la evaluación final responde a decisiones fijadas sin haber visto esas 5 015 etiquetas. Los resultados de ambas etapas se comparan más adelante como referencias sobre corpus y protocolos distintos, no como una prueba controlada de superioridad.

3.4. Preprocesamiento y métricas

Las imágenes se corrigieron según EXIF, se convirtieron a RGB, se redimensionaron a la entrada nativa de cada backbone y se normalizaron con media y desviación de ImageNet. El redimensionamiento directo no conserva la relación de aspecto; es una limitación deliberadamente visible del protocolo. Cada foto se decodificó una vez durante la extracción conjunta, y FastViT recibió 256 píxeles mientras los otros backbones recibieron 224.

La métrica de selección fue macro-F1, porque concede el mismo peso a potasio y a la clase sana. También se guardaron accuracy, precision macro, recall macro y F1 ponderado. Accuracy permite continuidad con la etapa anterior; F1 ponderado describe el volumen total; macro-F1 evita que cualquiera de esas dos lecturas oculte las clases pequeñas. Para fairness se calcularon las mismas métricas dentro de grupos, pero sus brechas se reportan como diferencias descriptivas y no como causalidad.

4. Optimización del clasificador

4.1. Baseline de referencia

EfficientNet-B0 se mantuvo como punto de partida porque había obtenido el mejor macro-F1 de la Etapa 1. En la corrida nueva no se volvió a entrenar toda la red: se retiró su clasificador, se congelaron los 4 007 548 parámetros del backbone ImageNet y se extrajo un vector de 1 280 características por imagen. Sobre esos vectores se ajustó una regresión logística multiclase incremental con SGD.

El baseline interno de esta etapa usa $\alpha = 10^{-4}$, tasa constante 0.01, penalización L2, batch 256, promedio de pesos, normalización L2 de embeddings y 20 épocas. No debe confundirse con el EfficientNet-B0 end-to-end histórico. El primero sirve para aislar el efecto del tuning bajo el nuevo protocolo; el segundo conserva la referencia de 0.9146 macro-F1 sobre el corpus y test de la Etapa 1.

4.2. Espacio de hiperparámetros

Optuna se eligió porque el muestreador TPE usa los trials previos para concentrar la búsqueda y porque el pruning puede detener combinaciones que ya muestran un macro-F1 poco competitivo [1]. Se ejecutaron 30 trials con semilla 42. El objetivo fue macro-F1 en las 5 015 imágenes de validación; el holdout no participó.

La búsqueda cubrió α entre 10^{-6} y 10^{-3} en escala logarítmica, tasa inicial entre 3×10^{-4} y 5×10^{-2} también logarítmica, penalización L2 o elastic net, proporción L1 entre 0 y 0.5 cuando correspondía, batch de 128, 256 o 512, promedio de pesos activado o no, embeddings con o sin normalización L2 y potencia de balanceo 0, 0.5 o 1. Esta última transforma los pesos inversos de clase: cero no rebalancea, 0.5 aplica raíz cuadrada y uno usa la inversa completa.

Cuadro 2: Configuración del baseline interno y combinación seleccionada por Optuna.

Hiperparámetro	Baseline	Mejor valor
alpha	0.0001	4.2836449125618075e-06
eta0	0.01	0.0006059127453715242
penalty	l2	l2
l1_ratio	0.15	0.0
batch_size	256	512
balance_power	0.0	0.5
average	True	False
feature_norm	l2	none
epochs	20	20

El pruner fue *MedianPruner*, con cinco trials iniciales y cuatro épocas de calentamiento. Cada época reportó macro-F1, de modo que una configuración podía terminar antes de las veinte épocas. La tabla de trials, el historial por época y la importancia de parámetros se guardaron directamente desde el estudio.

4.3. Resultados del tuning




Figura 2: Macro-F1 de los trials completos y mejor valor acumulado. La línea discontinua corresponde al baseline de la cabeza, no al modelo histórico.




Figura 3: Importancia relativa calculada por Optuna dentro del espacio explorado. Una importancia baja no prueba que el hiperparámetro sea inútil fuera de esos rangos.

Cuadro 3: Cinco mejores trials completos según macro-F1 de validación.

Trial	Macro-F1 val.	Estado
26	0.8887	COMPLETE
11	0.8877	COMPLETE
12	0.8877	COMPLETE
23	0.8877	COMPLETE
22	0.8865	COMPLETE

Cuadro 4: Efecto observado del tuning sobre la misma división y backbone.

Configuración	Accuracy	Macro-F1	F1 ponderado
baseline probe	0.8742	0.7799	0.8685
optuna tuned probe	0.9382	0.8887	0.9383

Optuna completó 17 trials y pudo 13. El mejor fue el trial 26 en la numeración mostrada al lector (índice interno 25): penalización L2, $\alpha = 4.28 \times 10^{-6}$, tasa 0.000606, batch 512, potencia de balanceo 0.5, sin promedio de pesos y sin normalización L2 de embeddings. El patrón de los mejores trials fue consistente: una regularización pequeña, tasa menor que la del baseline y balanceo por raíz cuadrada.

El macro-F1 subió de 0.7799 a 0.8887, una ganancia absoluta de 0.1088 sobre la misma división. Accuracy pasó de 0.8742 a 0.9382 y el cambio mayor entre los componentes de macro-F1 apareció en recall macro: 0.7516 a 0.8914. Precision macro también aumentó, de 0.8511 a 0.8864. El baseline no fallaba solamente por falta de separación; estaba favoreciendo demasiado a las clases grandes. La raíz de los pesos inversos corrigió parte de ese sesgo sin llegar al balanceo completo, que varios trials llevaron a resultados peores.

La Figura 3 atribuye la mayor importancia a la penalización (0.261), seguida por tasa de aprendi-

zaje (0.189), promedio de pesos (0.186) y potencia de balanceo (0.176). Alpha quedó en 0.038 dentro de esta búsqueda. Esto no significa que la regularización sea irrelevante: los trials competitivos ya se concentraron en valores pequeños. La lectura útil es que no hizo falta aumentar la capacidad del backbone. La ganancia vino de cómo la cabeza convirtió sus características en fronteras para clases desiguales.

5. Modelos avanzados

5.1. Arquitecturas evaluadas

Se conservaron cuatro backbones con pesos ImageNet. EfficientNet-B0 escala profundidad, ancho y resolución de forma conjunta [8]; ShuffleNetV2-x1.0 prioriza operaciones eficientes y menor movimiento de memoria [3]; MobileNetV3 Small fue diseñado mediante búsqueda para dispositivos con recursos limitados [2]; FastViT-T8 combina bloques convolucionales e ideas de transformers visuales con reparametrización estructural [9].

Los cuatro recibieron exactamente las mismas filas de entrenamiento y validación y la configuración de cabeza seleccionada con EfficientNet-B0. Transferir esa misma cabeza metodológica evita darle a cada arquitectura una búsqueda de 30 trials diferente, aunque también favorece parámetros que fueron escogidos sobre B0. Los resultados miden la calidad de la representación congelada, no un ranking definitivo después de fine-tuning.

El registro de código también admite EfficientNet-Lite0, EfficientNet-B4, MobileNetV3 Large y GhostNetV2-100. Registrado significa que el constructor puede instanciarlo; evaluado significa que produjo embeddings para las 33 433 imágenes y un CSV de predicciones en este protocolo. Solo los cuatro modelos de la Tabla 5 cumplen la segunda condición.

5.2. Comparación experimental

Cuadro 5: Backbones evaluados con la misma cabeza optimizada. MB representa el tamaño FP32 estimado de parámetros del backbone; ms es la mediana de 30 inferencias de una imagen en CPU.

Modelo	Parám.	MB	ms	Acc.	P-macro	R-macro	F1-macro
EfficientNet-B0	4.01 M	15.3	24.3	0.9382	0.8864	0.8914	0.8887
ShuffleNetV2-x1.0	1.25 M	4.8	9.5	0.9264	0.8710	0.8691	0.8694
MobileNetV3 Small	1.52 M	5.8	5.2	0.9194	0.8614	0.8710	0.8651
FastViT-T8	3.26 M	12.4	23.5	0.9194	0.8591	0.8603	0.8593




Figura 4: Relación entre macro-F1, tamaño FP32 y latencia del backbone. El color de cada punto corresponde a la latencia CPU.

La latencia separó dos grupos aun antes de mirar la calidad. MobileNetV3 Small registró 5.2 ms y ShuffleNetV2-x1.0 9.5 ms por backbone; FastViT-T8 y EfficientNet-B0 rondaron 23.5 y 24.3 ms. Estas mediciones excluyen lectura de archivo, preprocesamiento y cabeza, y proceden de un Intel Core i7-12800HX. No son una predicción de tiempo Android.

EfficientNet-B0 conservó el primer lugar: 0.9382 de accuracy y 0.8887 de macro-F1. ShuffleNet quedó segundo con 0.9264 y 0.8694. La diferencia de macro-F1 fue 0.0193, mientras ShuffleNet utilizó cerca del 31 de parámetros de B0 y el 39. Etapa 1: B0 ofrece la mejor calidad; ShuffleNet pierde poco y reduce de forma marcada el costo.

MobileNetV3 Small fue todavía más rápido, 5.2 ms, pero su macro-F1 bajó a 0.8651. Frente a ShuffleNet ahorra aproximadamente 4.2 ms en esta CPU a cambio de 0.0043 de macro-F1. Ese intercambio puede ser razonable en un teléfono lento, aunque requiere una medición Android antes de elegirlo. FastViT-T8 no justificó aquí su costo: obtuvo el macro-F1 menor, 0.8593, con latencia similar a EfficientNet-B0 y más parámetros que los otros dos modelos móviles.

La comparación tampoco respalda la idea de que una arquitectura más reciente deba ganar automáticamente. El backbone híbrido fue competitivo en accuracy (0.9194), pero su promedio por clase dejó ver que la representación no separó las minorías tan bien como B0. Por eso EfficientNet-B0 pasó a la fase de ensemble como mejor candidato individual y no por continuidad histórica.

6. Ensemble

6.1. Complementariedad antes de combinar

Un ensemble solamente puede ayudar si sus componentes aportan información distinta. Se guardaron las nueve probabilidades de cada modelo para las 5015 imágenes de validación y se compararon sus conjuntos de error. Para cada pareja se calculó la intersección y el Jaccard de errores. Un

Jaccard cercano a uno indica que ambos fallan en casi los mismos casos; un valor menor deja más margen para que un voto corrija a uno con el otro.

Se probaron dos combinaciones. El soft voting uniforme promedió las probabilidades de los cuatro componentes. El weighted soft voting asignó un peso no negativo a cada uno, normalizó la suma y optimizó esos pesos con 250 trials TPE. Ni las etiquetas ni las probabilidades del holdout se usaron para esa decisión.

6.2. Resultado de la combinación

Cuadro 6: Mejor componente individual frente a los dos ensembles en validación.

Método	Accuracy	P-macro	R-macro	F1-macro	F1 pond.
EfficientNet-B0	0.9382	0.8864	0.8914	0.8887	0.9383
uniform soft voting	0.9535	0.9129	0.9104	0.9116	0.9535
weighted soft voting	0.9539	0.9209	0.9197	0.9202	0.9539




Figura 5: Cambio de macro-F1 al combinar los cuatro modelos. La escala se acota para que una diferencia pequeña no desaparezca visualmente.

La regla de selección fue simple y se fijó antes del holdout: conservar el método con mayor macro-F1 de validación, aunque fuera un modelo individual. Así el ensemble no obtiene preferencia solamente por ser más complejo. Si la ganancia no compensa cuatro backbones, el resultado negativo sigue siendo útil para despliegue.

La complementariedad sí existió. EfficientNet-B0 cometió 310 errores de validación y MobileNetV3 Small 404, pero solamente 155 fueron compartidos; su Jaccard de errores fue 0.277, el menor de las seis parejas. B0 y ShuffleNet compartieron 149 errores y obtuvieron Jaccard 0.281. Los modelos más débiles no se limitaron a repetir los fallos de B0, de modo que sus probabilidades podían corregir parte de ellos.

El promedio uniforme elevó macro-F1 de 0.8887 a 0.9116. La optimización de pesos lo llevó a 0.9202, con 0.9539 de accuracy y 0.9197 de recall macro. Los pesos normalizados fueron 0.3658

para EfficientNet-B0, 0.2664 para ShuffleNet, 0.2480 para MobileNetV3 y 0.1197 para FastViT. La búsqueda no eliminó los componentes de menor F1; les asignó menos influencia porque todavía corregían casos distintos.

La ganancia del weighted soft voting frente al mejor individuo fue 0.0315 de macro-F1 y frente al voto uniforme 0.0086. Por esa razón pasó a validación cruzada y holdout. El costo también se acumula: los backbones suman cerca de 38.3 MB en parámetros FP32 y aproximadamente 62.4 ms de latencia medida por separado en esta CPU. Es la mejor selección estadística del experimento, no la opción móvil más barata.

7. Validación cruzada

7.1. Diseño

Después de fijar hiperparámetros, arquitectura o ensemble se unieron entrenamiento y validación en un conjunto de desarrollo de 28 418 imágenes. Sobre él se ejecutó StratifiedKFold de cinco partes, con barajado y semilla 42. La estratificación utilizó la combinación clase-entorno para impedir que uno de los folds perdiera los pocos ejemplos de roya de campo o concentrara los fondos de laboratorio.

En cada fold la cabeza se ajustó desde cero sobre cuatro partes y se evaluó en la quinta. Cuando la selección fue un ensemble, se reajustó una cabeza para cada backbone y se conservaron los pesos de voting aprendidos antes. No se volvieron a optimizar pesos dentro de los folds. Esto mide estabilidad de la configuración fijada y evita cinco búsquedas nuevas.

Cuadro 7: Resultados de cinco folds, media y desviación estándar muestral.

Fold	Accuracy	P-macro	R-macro	F1-macro	F1 pond.
1	0.9562	0.9140	0.9144	0.9118	0.9559
2	0.9518	0.9112	0.9080	0.9077	0.9516
3	0.9555	0.9264	0.9160	0.9195	0.9553
4	0.9527	0.9172	0.9123	0.9140	0.9525
5	0.9495	0.9026	0.8923	0.8955	0.9490
Media	0.9531	0.9143	0.9086	0.9097	0.9529
Desv.	0.0027	0.0087	0.0096	0.0090	0.0028




Figura 6: Macro-F1 por fold y media de la configuración seleccionada.

Esta validación no vuelve ciega la selección: Optuna y la comparación ya habían visto una división del mismo conjunto de desarrollo. Su función es comprobar si el resultado depende de un corte afortunado. El estimador no consultado permanece en el holdout.

Los cinco folds produjeron 0.9097 de macro-F1 medio con desviación 0.0090. El mejor fue el tercero (0.9195) y el menor el quinto (0.8955); la distancia entre ambos fue 0.0240. Accuracy varió mucho menos, con media 0.9531 y desviación 0.0027. Esa diferencia entre la estabilidad de accuracy y macro-F1 vuelve a mostrar que el movimiento ocurre en las clases pequeñas, no en el grueso del dataset.

Potasio fue al mismo tiempo la clase con menor F1 medio (0.7039) y la más variable (desviación 0.0496). En el quinto fold su recall cayó a 0.5524 y su F1 a 0.6304, aun cuando el accuracy global permaneció en 0.9495. Nitrógeno quedó segundo entre los promedios bajos, con F1 0.8326, pero su desviación fue 0.0159. Roya común y necrosis letal superaron 0.98 de F1 medio con variaciones menores a 0.002.

La configuración es estable para las clases grandes y visualmente distintivas, pero no para potasio. El fold bajo no invalida el ensemble; evita resumirlo como 0.91 sin decir que una partición produjo 0.63 de F1 en el problema central de la etapa anterior. Esa variación justifica mantener métricas por clase en el monitoreo del prototipo.

8. Evaluación final

8.1. Apertura única del holdout

Una vez fijados la configuración de la cabeza, los modelos participantes y la regla de voting, cada cabeza se reajustó con las 28418 imágenes de desarrollo. El proceso comprobó que no existiera previamente `outputs/etapa_2/final/metrics.json`; después creó el directorio final, evaluó las 5015 filas congeladas y registró `evaluation_count=1`. El JSON conserva además el hash del CSV de holdout. Esta protección no es criptográfica frente a una persona que borre archivos, pero deja

auditable la ejecución usada por el informe.

8.2. Resultados globales y por clase

Cuadro 8: Métricas obtenidas en la única evaluación del holdout.

Accuracy	P-macro	R-macro	F1-macro	F1 pond.	N
0.9537	0.9012	0.9092	0.9035	0.9537	5015

Cuadro 9: Precision, recall y F1 finales para las nueve clases.

Clase	Soporte	Precision	Recall	F1
Roya común	338	0.9970	0.9675	0.9820
Gusano cogollero	729	0.9517	0.9739	0.9627
Mancha gris	290	0.9027	0.9276	0.9150
Sana	1311	0.9674	0.9748	0.9711
Necrosis letal	962	0.9927	0.9896	0.9912
Def. nitrógeno	127	0.7386	0.8898	0.8071
Tizón norteño	1024	0.9653	0.9248	0.9446
Def. fósforo	141	0.8553	0.9220	0.8874
Def. potasio	93	0.7403	0.6129	0.6706




Figura 7: Rendimiento final por clase. El soporte desigual no cambia el peso de cada barra en macro-F1.

El ensemble obtuvo 0.9537 de accuracy y F1 ponderado, 0.9012 de precision macro, 0.9092 de recall macro y 0.9035 de macro-F1. El resultado quedó 0.0062 por debajo de la media de validación cruzada y dentro de una desviación estándar de ella. La validación fija había sido más optimista (0.9202), algo esperable porque allí también se eligieron los pesos.

La diferencia entre accuracy y macro-F1 vuelve a concentrarse en tres clases. Necrosis letal obtuvo F1 0.9912 y roya común 0.9820; sana, gusano cogollero y tizón norteño también superaron 0.94. Potasio quedó en 0.6706, nitrógeno en 0.8071 y fósforo en 0.8874. El ensemble mantiene el rendimiento global, pero no convierte las deficiencias en un problema resuelto.

8.3. Matriz de confusión

		Conteos												Normalizada por clase real																							
Clase real		Roya común	327	0	5	1	0	0	5	0	0		Clase real		Roya común	0.97	0.00	0.01	0.00	0.00	0.00	0.01	0.00	0.00		Clase real		Roya común	0.97	0.00	0.01	0.00	0.00	0.00	0.01	0.00	0.00
	Gusano cogollero	0	710	0	9	0	0	3	5	2		Gusano cogollero		0.00	0.97	0.00	0.01	0.00	0.00	0.00	0.00	0.01	0.00	0.00			Gusano cogollero	0.00	0.97	0.00	0.01	0.00	0.00	0.00	0.01	0.01	0.00
	Mancha gris	0	2	269	2	3	1	13	0	0		Mancha gris		0.00	0.01	0.93	0.01	0.01	0.00	0.00	0.04	0.00	0.00		Mancha gris		0.00	0.01	0.93	0.01	0.01	0.00	0.00	0.04	0.00	0.00	
	Sana	0	14	2	1278	2	0	9	6	0		Sana		0.00	0.01	0.00	0.97	0.00	0.00	0.01	0.00	0.00	0.00		Sana		0.00	0.01	0.00	0.97	0.00	0.00	0.01	0.00	0.00	0.00	
	Necrosis letal	0	1	1	5	952	1	2	0	0		Necrosis letal		0.00	0.00	0.00	0.01	0.99	0.00	0.00	0.00	0.00	0.00		Necrosis letal		0.00	0.00	0.00	0.01	0.99	0.00	0.00	0.00	0.00	0.00	
	Def. nitrógeno	0	2	0	0	0	113	2	2	8		Def. nitrógeno		0.00	0.02	0.00	0.00	0.00	0.89	0.02	0.02	0.02	0.06		Def. nitrógeno		0.00	0.02	0.00	0.00	0.00	0.89	0.02	0.02	0.02	0.06	
	Tizón norteño	1	13	21	25	1	9	947	4	3		Tizón norteño		0.00	0.01	0.02	0.02	0.00	0.01	0.92	0.00	0.00		Tizón norteño	0.00		0.01	0.02	0.02	0.00	0.01	0.92	0.00	0.00			
	Def. fósforo	0	3	0	0	0	1	0	130	7		Def. fósforo		0.00	0.02	0.00	0.00	0.00	0.01	0.00	0.92	0.05		Def. fósforo	0.00		0.02	0.00	0.00	0.00	0.01	0.00	0.92	0.05			
	Def. potasio	0	1	0	1	1	28	0	5	57		Def. potasio		0.00	0.01	0.00	0.01	0.01	0.30	0.00	0.05	0.61		Def. potasio	0.00		0.01	0.00	0.01	0.01	0.30	0.00	0.05	0.61			
			Predicción													Predicción																					
		Roya común	Gusano cogollero	Mancha gris	Sana	Necrosis letal	Def. nitrógeno	Tizón norteño	Def. fósforo	Def. potasio					Roya común	Gusano cogollero	Mancha gris	Sana	Necrosis letal	Def. nitrógeno	Tizón norteño	Def. fósforo	Def. potasio					Roya común	Gusano cogollero	Mancha gris	Sana	Necrosis letal	Def. nitrógeno	Tizón norteño	Def. fósforo	Def. potasio	

Figura 8: Matriz final en conteos y normalizada por clase real. La segunda vista permite leer clases pequeñas sin que desaparezcan detrás de la clase sana.

Hubo 232 errores en 5,015 imágenes. Los dos flujos individuales más grandes fueron potasio hacia nitrógeno (28 casos) y tizón norteño hacia sana (25). También aparecieron 21 casos de tizón como mancha gris y 13 en el sentido contrario. La matriz normalizada hace visible que los 36 fallos de potasio pesan mucho más para su clase que los 77 fallos totales de tizón para una clase con 1,024 ejemplos.

La diagonal de roya parece casi perfecta en conteos, pero esconde una diferencia de entorno que se revisa en fairness: 327 de 338 casos fueron correctos y los once errores se concentran proporcionalmente en las pocas imágenes de campo. El problema no está en reconocer el patrón de laboratorio, sino en sostenerlo cuando cambia la captura.

8.4. Etapa 1 frente a Etapa 2

Cuadro 10: Referencias de ambas etapas. Accuracy y macro-F1 no son una comparación controlada porque cambiaron corpus, división y entrenamiento.

Métrica	Etapa 1	Etapa 2	Lectura
Accuracy	0.9521	0.9537	Corpus y protocolo distintos
Macro-F1	0.9146	0.9035	Corpus y protocolo distintos
Recall potasio	—	0.6129	No comparable
F1 potasio	0.62	0.6706	Referencia B0 histórica
Imágenes potasio	266	621	+355

La tabla no atribuye el cambio a Optuna ni a la ampliación. El contraste controlado de tuning está en la Tabla 4; aquí la Etapa 1 aporta el antecedente del proyecto y la Etapa 2 aporta un holdout que sí permaneció cerrado. Esta diferencia metodológica vale más que aparentar una ganancia directa entre dos números obtenidos bajo condiciones distintas.

Como referencia, accuracy cambió de 0.9521 a 0.9537 y macro-F1 de 0.9146 a 0.9035. No se interpreta la caída de 0.0111 como empeoramiento causal: el holdout nuevo contiene otro corpus y la cabeza no fue ajustada end-to-end. En potasio, el F1 pasó de 0.62 a 0.6706 y el soporte evaluado de 40 a 93. La señal es favorable, pero todavía insuficiente y tampoco aislable de los cambios de datos y protocolo.

9. Análisis de errores

El análisis se hizo a partir de las 5015 predicciones del holdout y no de una selección visual de casos convenientes. La matriz de conteos permite seguir cada error desde su clase real hasta la predicción. También se separaron los errores con mayor confianza para comprobar si el problema detectado en la Etapa 1 seguía presente.

9.1. Deficiencias de nitrógeno, fósforo y potasio

Las tres deficiencias reunieron 61 errores y 51 de ellos (83.6%) a otra clase del mismo bloque N/P/K. Nitrógeno tuvo 127 ejemplos: ocho se predijeron como potasio y dos como fósforo. Fósforo tuvo 141: siete pasaron a potasio y uno a nitrógeno. Potasio tuvo 93 y produjo el flujo más grande: 28 a nitrógeno y cinco a fósforo. La confusión no desapareció al ampliar el corpus; se volvió más asimétrica. El modelo suele absorber potasio dentro de nitrógeno, pero también recibe falsos positivos de las otras deficiencias.

9.2. Potasio: el cuello de botella anterior

Solo 57 de las 93 imágenes de potasio fueron correctas. Su precision fue 0.7403, recall 0.6129 y F1 0.6706. De los 36 errores, 28 terminaron en nitrógeno (77.8%) y 8 en fósforo. El problema principal no es una dispersión aleatoria por nueve clases; es una frontera concreta entre amarillamientos nutricionales.

Frente al F1 histórico de 0.62 existe una mejora orientativa de 0.0506 y el soporte de evaluación aumentó de 40 a 93. Sin embargo, el recall sigue dejando sin reconocer casi cuatro de cada diez casos y en validación cruzada osciló con desviación 0.0496. Potasio mejoró, pero continúa siendo el cuello de botella.

9.3. Mancha gris y tizón norteño

Mancha gris acertó 269 de 290 imágenes. Trece de sus 21 errores fueron hacia tizón norteño. En el sentido inverso, 21 de 77 errores de tizón terminaron en mancha gris; otros 25 se clasificaron como sanos. La relación visual detectada en la Etapa 1 permanece, aunque sus F1 finales de 0.9150 y 0.9446 están muy por encima del bloque nutricional. Aquí el modelo falla en una minoría de lesiones parecidas; en potasio falla en la estructura central de la clase.

9.4. Errores de alta confianza

Siete de los 232 errores superaron 0.90 de confianza. El mayor fue una imagen de fósforo predicha como potasio con 0.9779. Tres hojas enfermas —dos con gusano cogollero y una con tizón— se mostraron como sanas con confianza entre 0.9296 y 0.9571; otra hoja de tizón recibió sana con 0.9145. También hubo roya de campo como mancha gris (0.9178) y mancha gris de laboratorio como tizón (0.9143).

Los casos más confiados cruzan precisamente dos límites de riesgo: confundir insumos dentro de N/P/K y declarar sana una hoja afectada. El ensemble reduce errores globales, pero no elimina la sobreconfianza. La interfaz debe mostrar la segunda posibilidad, permitir rechazo y evitar convertir el porcentaje en una orden de manejo.

La confianza máxima utilizada aquí procede de probabilidades one-vs-rest normalizadas. Sirve para ordenar los casos, pero no está calibrada. Un error de 0.95 no demuestra que el sistema estuviera estadísticamente 95 % seguro; sí demuestra que la interfaz habría mostrado una alternativa dominante. Esos casos deben alimentar pruebas OOD, revisión de etiqueta y futuras corridas de calibración.

10. Interpretabilidad

La Etapa 1 ya explicó LIME y Grad-CAM; aquí se aplicaron al modelo final en vez de repetir su teoría. Se seleccionaron cinco situaciones desde el CSV del holdout: acierto fácil, acierto difícil, error de alta confianza, deficiencia nutricional de potasio y una imagen de laboratorio con fondo controlado. La selección fue programática y el archivo `cases.csv` conserva ruta, etiqueta, predicción, confianza, entorno y fuente.

Cuando el método final fue un ensemble, se calculó Grad-CAM para la clase predicha en la última capa convolucional de cada componente. Cada mapa se normalizó y se combinó con los mismos pesos del soft voting. La visualización localiza regiones que influyeron en los componentes, pero sigue siendo una aproximación de la decisión conjunta. Grad-CAM no prueba que la región sea una causa biológica [7].




Figura 9: Casos del holdout y mapas Grad-CAM del método final. El color rojo marca mayor activación relativa dentro de cada imagen.

El acierto difícil de fósforo tuvo solamente 0.283 de confianza y concentró la activación sobre la nervadura con coloración púrpura. El modelo miró una señal coherente y aun así dejó probabilidades cercanas para otras clases. En el caso de potasio predicho como nitrógeno (0.269), el mapa cayó sobre el borde amarillento y necrótico. Aquí el modelo mira el lugar correcto y aun así se equivoca: el problema está en separar dos patrones nutricionales, no en haber ignorado la hoja.

El error de mayor confianza cuenta otra historia. La imagen de fósforo clasificada como potasio con 0.978 activa con fuerza el borde de la maceta y el suelo alrededor, mientras buena parte de la hoja queda fría. Ese caso combina fondo, encuadre vertical y amarillamiento, y muestra un atajo más preocupante que una frontera fina entre lesiones. Los dos aciertos de roya sobre fondo negro también producen zonas calientes cerca del contorno recortado. La red usa puntos de roya, pero el borde artificial participa en la decisión.

LIME se ejecutó sobre el error de alta confianza cuando existió uno; de lo contrario, sobre el acierto difícil. Se usaron 32 perturbaciones y ocho superpíxeles visibles sobre EfficientNet-B0, el componente con mayor peso del ensemble. A diferencia de Grad-CAM, LIME pregunta cómo cambia la salida al ocultar segmentos de esa imagen [6]. Con tan pocas perturbaciones se busca una comprobación cualitativa reproducible, no una estimación estable para todas las hojas ni una explicación del voto completo. La copia usada por LIME limita su lado mayor a 512 píxeles antes de generar perturbaciones; el clasificador de todas formas la reduce a 224.

Error de alta confianza | confianza del ensemble=0.978



Figura 10: Imagen final seleccionada y explicación local LIME. Los bordes corresponden a segmentos perturbados, no a una segmentación agronómica de la lesión.

La explicación LIME se aplicó al mismo error fósforo–potasio de 0.978. Los segmentos influyentes no quedaron encerrados en la hoja central: aparecen sobre un fragmento de su tejido, hojas vecinas, suelo y el borde de otra maceta. Junto con el Grad-CAM concentrado alrededor de la maceta superior, ambos métodos indican que la salida mezcla una señal foliar débil con el contexto de captura. La figura no se usa para corregir la etiqueta. Sirve para decidir qué tipo de ejemplo debe añadirse: hojas con síntomas semejantes, pero fondos y encuadres diferentes.

SHAP existe en la infraestructura histórica del repositorio, pero no se ejecutó sobre la cabeza final. Por esa razón no se incluye una figura SHAP reciclada como si perteneciera a esta corrida. La evidencia final de interpretabilidad son los mapas y metadatos generados por los dos métodos anteriores.

11. Sesgos y fairness

En Doctor Maíz, fairness no se refiere a atributos demográficos. Se pregunta si el clasificador mantiene un rendimiento parecido entre clases y condiciones de captura agrícola. El reporte se generó únicamente sobre el holdout final y calculó precision, recall y F1 por clase, entorno, fuente, tercil de resolución y tercil de blur. Para evitar grupos diminutos se exigieron al menos 30 imágenes por fuente y 20 en las demás dimensiones.

Cuadro 11: Diferencia entre el mayor y menor valor observado dentro de cada dimensión. Los gaps son descriptivos y no llevan signo.

Dimensión	Gap precision	Gap recall	Gap F1
class	0.2584	0.3767	0.3206
blur_bucket	0.0985	0.0910	0.0929
environment	0.0304	0.0996	0.0861
resolution_bucket	0.0710	0.0601	0.0683
source	0.2084	0.3599	0.3151

La brecha mayor apareció entre clases: 0.2584 en precision, 0.3767 en recall y 0.3206 en F1. El extremo inferior de precision fue nitrógeno (0.7386); el de recall y F1 fue potasio (0.6129 y 0.6706). Necrosis letal ocupó el extremo alto de recall y F1. La desigualdad entre clases es mayor que cualquiera de las brechas agregadas de calidad de imagen.

Fuente quedó muy cerca: gap 0.3151 en F1 y 0.3599 en recall. Blur produjo 0.0929 de F1; entorno 0.0861; resolución 0.0683. Que entorno tenga un gap global menor no contradice el sesgo de fondos: sus dos grupos contienen conjuntos de clases distintos y por eso se necesita la lectura controlada siguiente.

11.1. Laboratorio frente a campo




Figura 11: A la izquierda, macro métricas globales de grupos con composición de clases distinta; a la derecha, recall dentro de las clases presentes en ambos entornos.

En el resumen global, laboratorio obtuvo F1 0.9352 y campo 0.8491; los recalls fueron 0.9371 y 0.8376. No se concluye que retirar el fondo cause 0.0861 de ganancia. Laboratorio no contiene

deficiencias y el grupo de campo sí incluye potasio, la clase más difícil.

Dentro de mancha gris el recall fue 0.9091 en laboratorio y 0.9343 en campo; para tizón norteño, 0.9023 y 0.9282. Esas dos clases no muestran una caída de campo. Roya sí: 1.0000 sobre 322 imágenes de laboratorio y 0.3125 sobre solo 16 de campo. El tamaño de ese último grupo impide generalizar el número, pero confirma el atajo advertido en la Etapa 1: reconocer roya sobre fondo controlado no garantiza reconocer sus pocas capturas reales.

La mitad izquierda no se interpreta como efecto causal del fondo. Laboratorio solo contiene roya, mancha gris y tizón norteño, mientras campo contiene las nueve categorías. La comparación dentro de clase reduce ese problema para tres categorías, aunque todavía puede mezclar fuente, cámara y resolución.

11.2. Fuente, resolución, nitidez y clases pequeñas

Entre fuentes, `maize_field` tuvo el F1 menor (0.6849), mientras `maize_leaf_robotflow` alcanzó 1.0000 en su subconjunto. La diferencia no compara colecciones equivalentes: una fuente puede aportar una sola clase o un estilo particular. Su utilidad es operativa: antes de añadir nuevas imágenes de `maize_field` conviene revisar por qué casi un tercio de su rendimiento queda fuera del extremo superior.

El tercil con mayor desenfoque aparente obtuvo F1 0.8022 y el más nítido 0.8951. La dirección coincide con lo esperado: menos detalle acompaña más errores. En cambio, resolución no fue monótona. El tercil medio quedó en 0.8425 y el de menor resolución en 0.9108. Más píxeles originales no aseguran que la lesión esté grande, enfocada o bien iluminada; usar resolución como filtro automático habría descartado casos sin evidencia suficiente.

El indicador de blur es la varianza del Laplaciano de una copia reducida. Una lesión con textura puede elevarlo y una hoja correctamente enfocada pero lisa puede reducirlo; por eso se habla de terciles de nitidez aparente. De forma similar, resolución original no garantiza que la hoja ocupe suficientes píxeles. Estas variables ayudan a encontrar segmentos débiles, no sustituyen una auditoría de calidad de captura.

El informe evita la frase *¡el modelo es justo!*. Un gap pequeño en este holdout solo significa que los grupos definidos aquí quedaron cerca. Sin ubicación, finca, variedad o dispositivo no se puede descartar una brecha regional. El formato sigue el principio de una ficha de modelo: mostrar soporte, condiciones y límites junto con la métrica [4].

12. Consideraciones éticas

El riesgo principal de Doctor Maíz no es que una métrica baje unas décimas, sino que una persona convierta una predicción en una acción sobre el cultivo. Un falso negativo puede retrasar la consulta cuando la planta presenta necrosis letal o tizón. Un falso positivo de deficiencia puede inducir una aplicación de fertilizante que no era necesaria. También puede existir una predicción visualmente razonable pero agronómicamente incompleta: síntomas parecidos pueden tener causas distintas y una fotografía no contiene información sobre suelo, clima, etapa fenológica o evolución temporal.

12.1. Confianza y comunicación del resultado

La interfaz no presenta el resultado como un diagnóstico confirmado. Muestra probabilidad, segunda clase cuando la confianza es menor de 0.70 y un mensaje específico cuando el detector fuera de dominio rechaza la imagen. La demo experimental emplea un umbral de 0.60 para advertir baja confianza y acompaña cada salida con la frase “Apoyo orientativo; no sustituye la evaluación de un profesional agrónomo”. Estos umbrales son controles de interfaz, no garantías estadísticas. No se ejecutó una calibración formal sobre el holdout y, por tanto, 80 % de confianza no debe leerse como 80 % de certeza clínica o agronómica.

El rechazo fuera de dominio de la aplicación usa distancia relativa de Mahalanobis sobre un segundo tensor de características. Además, rechaza distribuciones con poca separación. Esto reduce el riesgo de clasificar una persona, una herramienta o una hoja de otra especie como una de las nueve clases. No cubre todas las imágenes extrañas posibles y pertenece al modelo móvil histórico, no al ensemble experimental. La selección de Etapa 2 todavía no incorpora su propio detector OOD.

12.2. Errores con costos distintos

Las nueve clases no tienen el mismo costo de error. Confundir nitrógeno con potasio puede terminar en una recomendación de manejo distinta; confundir una hoja sana con una enfermedad puede causar gasto y preocupación; declarar sana una hoja enferma puede demorar atención. El entrenamiento optimiza macro-F1, que protege estadísticamente a las clases pequeñas, pero no incorpora una matriz de costos agronómicos. Esa matriz debe definirse con especialistas y con información de manejo local antes de convertir el modelo en un sistema de decisión.

Por esa razón las recomendaciones de la app deben entenderse como pasos de inspección: revisar otras hojas, observar la distribución del síntoma, repetir la captura y consultar asistencia técnica. No corresponde indicar dosis o productos solamente a partir del logit más alto. Una recomendación automática de insumos sería una función nueva, con riesgos y validación distintos a los de clasificar una imagen.

12.3. Datos, ubicación y trazabilidad

La base móvil almacena localmente ruta de imagen, etiqueta, confianza, distribución y fecha. También reserva campos opcionales de latitud y longitud. La operación offline evita enviar cada fotografía por defecto, pero no elimina el riesgo de privacidad si más adelante se sincroniza una contribución. La ubicación de una parcela puede revelar domicilio, patrón productivo o actividad económica. Debe solicitarse consentimiento separado, explicar el propósito, reducir precisión cuando no sea necesaria y permitir borrar el dato.

Cada predicción que se use para seguimiento debería conservar versión del modelo, hash del artefacto, fecha y origen del resultado. La aplicación inspeccionada valida el orden de etiquetas y el contrato de tensores; el manifiesto del modelo registra arquitectura y SHA-256. Esa trazabilidad evita un problema concreto: que una corrección del usuario quede asociada a un modelo distinto del que produjo el diagnóstico.

12.4. Supervisión y salida segura

El sistema debe permitir sólo séz. Una foto desenfocada, una hoja pequeña dentro del encuadre o una condición que no pertenece a las nueve clases necesita terminar en repetición de captura o consulta, no en una recomendación forzada. El protocolo de campo propuesto incluye revisar varios órganos de la planta y no actuar sobre una sola imagen. Las correcciones guardadas por productores o extensionistas tampoco deben incorporarse automáticamente al entrenamiento: primero requieren revisión agronómica, control de duplicados y registro de procedencia.

Estas medidas no convierten el sistema en inocuo. Hacen visible dónde termina la clasificación y dónde empieza una decisión humana. Ese límite es especialmente necesario porque las métricas finales provienen de colecciones públicas y no de una validación prospectiva en parcelas salvadoreñas.

13. Prototipo funcional

13.1. Arquitectura verificada

La evidencia operativa combina dos piezas. La primera es la demo reproducible de esta etapa, que ejecuta la selección final sobre una imagen real. La segunda es la aplicación móvil Doctor Maíz inspeccionada en el commit `dd048d37dcabd08c53c704d702825e7d672f0f37`. La aplicación usa React Native 0.86, Expo 57, TypeScript, WatermelonDB y `react-native-fast-tflite`. El modelo embarcado es EfficientNet-Lite0 TFLite con pesos int8, entrada y salida float32 y tamaño de 3 743 824 bytes. Su SHA-256 coincide con el manifiesto:

3a0623cd985a23b954e424e605a2e00c91f8d592e376dfe3149e5820485bc2b3.




Figura 12: Flujo real implementado en la aplicación móvil. La API participa en autenticación, sincronización y actualización; la inferencia ocurre en el dispositivo.

El motor materializa el modelo como archivo local, comprueba que el tensor de entrada tenga $1 \times 3 \times 224 \times 224$ elementos y que existan nueve salidas en el orden de `labels.json`. También exige un segundo tensor de características para el detector OOD. La pantalla de captura acepta cámara o galería, ejecuta preprocesamiento e inferencia, navega al resultado y guarda el escaneo. La pantalla siguiente muestra la fotografía, diagnóstico, confianza, segunda opción en casos de confianza baja y recomendaciones. Si la imagen se rechaza, no fuerza una enfermedad: pide acercarse a una hoja con mejor luz.

13.2. Comprobación ejecutable

Se instaló el lockfile del repositorio móvil en un clon temporal. La instalación normal detectó un conflicto entre React Native 0.86.0 y `@react-native/jest-preset 0.86.2`; se completó con `npm ci --legacy-peer-deps`. Después, `npm run typecheck` terminó sin errores y `npm test -- --runInBand`

aprobó 40 suites y 276 pruebas. Las advertencias de React sobre `act(...)` no cambiaron el código de salida. El entorno disponible usa Node 18.19.1 aunque dependencias recientes solicitan Node 20.19.4 o superior; reproducir la app requiere alinear esa versión. La instalación también reportó 24 vulnerabilidades de dependencias (17 moderadas y 7 altas). No se ejecutó una actualización forzada porque habría cambiado el lockfile del prototipo; deben revisarse antes de distribuir otra compilación.

La Figura 13 es una captura generada por ejecución, no una maqueta. El comando carga los pesos públicos del o de los backbones seleccionados, aplica la cabeza final y escribe un JSON con Top-3, confianza y latencia CPU. Se usa una imagen del holdout solo después de terminar la evaluación final.




Figura 13: Captura de la demo de Etapa 2: entrada real y salida producida por el pipeline final. La latencia corresponde a CPU de escritorio y no se presenta como benchmark Android.

La demo se reproduce desde la raíz del clasificador con:

```
PYTHONPATH=./tmp/doctor-maiz-pydeps python \
  scripts/etapa_2/stage2_experiments.py \
  --output-dir outputs/etapa_2 demo --image /ruta/hoja.jpg
```

13.3. Qué modelo está desplegado

La aplicación móvil conserva EfficientNet-Lite0 de la línea de entrenamiento principal, no la cabeza congelada evaluada en esta etapa. Hacer el reemplazo habría requerido exportar conjuntamente backbone, escalado y regresión one-vs-rest, validar paridad y volver a medir OOD en Android. Ninguna de esas pruebas se ejecutó, así que el informe no afirma un despliegue que no ocurrió. El prototipo demuestra que la arquitectura de integración existe y que el artefacto histórico funciona dentro de ella; la demo demuestra que la selección experimental produce resultados reproducibles.

Durante una primera consulta, el endpoint de salud respondió `{"status": ".%k"}` y el endpoint de versión informó Android 1.0.0, código 6. En la verificación final del mismo día, el dominio dejó de resolver por DNS y la URL de APK sin autenticación devolvió HTTP 404. Por eso el prototipo

se califica como funcional e integrado, pero no como un despliegue público con disponibilidad comprobada de extremo a extremo. Esta diferencia reduce la puntuación del criterio y queda como limitación operativa, no como pendiente oculto.

14. Impacto social

14.1. Una herramienta de primera observación

Para un pequeño productor, el valor posible de Doctor Maíz no está en reemplazar un laboratorio ni en emitir una receta. Está en reducir la distancia entre notar un síntoma y formular una pregunta útil. Una foto puede sugerir si el patrón se parece más a roya, tizón, daño de gusano cogollero o una deficiencia, mostrar alternativas y conservar un registro para enseñarlo a un extensionista. La detección temprana solo ocurre si la captura se hace cuando el síntoma es visible y si la respuesta conduce a una revisión posterior.

La operación local cambia la viabilidad en zonas con conexión irregular. El modelo móvil no necesita enviar la fotografía para inferir y WatermelonDB conserva historial y correcciones hasta que exista conectividad. Esto reduce consumo de datos y permite trabajar en una parcela sin señal. También concentra el costo en el teléfono: cámara, memoria y tiempo de inferencia deben ser aceptables en dispositivos de gama baja, algo que todavía no se midió con una muestra representativa de equipos.

14.2. Productores y extensionistas

Usado individualmente, el sistema puede ayudar a organizar observaciones: fotografiar varias hojas, comparar confianza, anotar una corrección y decidir si hace falta asistencia. Usado por extensionistas, puede funcionar como una ficha común para priorizar visitas y recopilar ejemplos difíciles. El segundo uso parece más seguro porque una persona con experiencia interpreta el resultado junto con etapa del cultivo, distribución del daño y condiciones del suelo.

La cobertura de nueve clases limita ambas funciones. El maíz puede presentar otras enfermedades, daños por herbicida, sequía, plagas o síntomas combinados. Una categoría ausente no se convierte en visible por tener un detector OOD. El usuario necesita una salida clara para ninguna de las anteriores y una ruta de consulta. De lo contrario, la facilidad de tomar una foto puede producir más confianza de la que permite el dataset.

14.3. Beneficio posible y evidencia disponible

El proyecto no midió aumento de rendimiento, ahorro de fertilizante, reducción de pérdidas ni tiempo de respuesta de asistencia técnica. Atribuirle cualquiera de esos porcentajes sería inventar impacto. Lo que sí se comprobó es una cadena técnica: clasificación sobre un corpus amplio, evaluación separada, análisis por condiciones, inferencia local y mecanismo de corrección. Esa cadena hace posible una prueba de campo; todavía no demuestra un beneficio agronómico.

Una evaluación de impacto debería comparar prácticas, no solamente modelos. Por ejemplo, se pueden asignar comunidades o extensionistas a tres condiciones: procedimiento habitual, acceso a

Doctor Maíz y acceso a Doctor Maíz con revisión técnica. Las medidas relevantes serían tiempo hasta la consulta, concordancia con diagnóstico agronómico, decisiones evitadas por baja confianza y tasa de seguimiento. Rendimiento e insumos solo deberían medirse con un diseño que controle clima, variedad y manejo.

14.4. Riesgos de exclusión

El lenguaje, la alfabetización digital y el diseño del teléfono influyen tanto como el clasificador. Mostrar nombres en inglés, cifras sin explicación o pantallas cargadas puede excluir a la población a la que se busca apoyar. La aplicación ya presenta etiquetas y recomendaciones en español, pero no se realizó una prueba de usabilidad con productores. Tampoco se evaluaron variantes lingüísticas, accesibilidad visual o instrucciones por audio.

El dataset introduce otra exclusión: proviene de colecciones externas y no identifica municipios salvadoreños. Un macro-F1 alto puede convivir con fallos en una variedad local, una cámara económica o una iluminación no representada. Por eso el despliegue responsable empieza pequeño, registra contexto con consentimiento y permite detener el uso si una región muestra una brecha persistente.

14.5. Condiciones para uso real

Antes de promover el sistema a escala se necesitan, como mínimo: validación prospectiva en parcelas; revisión de etiquetas por profesionales; protocolo de captura sencillo; prueba en teléfonos de distintas gamas; monitoreo por región y clase; canal de corrección; política de datos y ubicación; y un responsable que revise incidentes. Bajo esas condiciones, Doctor Maíz puede ampliar el alcance de la asistencia. Sin ellas, solo traslada al teléfono la incertidumbre del dataset.

15. Recomendaciones de política pública

Las siguientes medidas son propuestas derivadas del experimento. No se presentan como programas vigentes ni como decisiones ya adoptadas.

1. **Crear un conjunto nacional con procedencia verificable.** Instituciones académicas, asociaciones de productores y servicios de extensión pueden acordar un esquema común para fotografías de hojas, con municipio a una resolución apropiada, variedad, etapa fenológica, fecha, dispositivo y diagnóstico de referencia. La diversidad regional debe medirse, no asumirse.
2. **Estandarizar la captura sin volverla artificial.** Cada registro debería incluir una vista cercana del síntoma y otra de la planta, bajo luz disponible, además de una guía de enfoque. El protocolo necesita ejemplos reales de fondos complejos; llenar el dataset de fondos blancos mejoraría el laboratorio y empeoraría la pregunta de campo.
3. **Establecer revisión agronómica de etiquetas.** Una corrección enviada desde la app no debe convertirse directamente en ground truth. Se requiere doble revisión para casos dudosos, registro del criterio usado y una categoría de desacuerdo. Las deficiencias N/P/K merecen prioridad porque su similitud visual fue el principal problema de ambas etapas.
4. **Usar el sistema como apoyo de extensión.** El primer despliegue debería entregar la herra-

mienta a equipos técnicos y a grupos acompañados de productores. Esto permite contrastar la predicción con síntomas de la parcela, corregir recomendaciones y definir cuándo la app debe derivar a una visita.

5. **Monitorear por región, clase y dispositivo.** Accuracy global no basta. Un tablero de operación debe seguir recall de clases críticas, tasa de rechazo, correcciones, latencia y brechas entre cámaras o zonas. Los grupos con soporte pequeño deben mostrarse con su incertidumbre y no ocultarse bajo promedios nacionales.
6. **Minimizar y proteger ubicación.** La georreferencia debe ser opcional, separada del uso básico y explicada en lenguaje claro. Cuando el objetivo sea vigilancia regional, puede almacenarse una cuadrícula o municipio en vez de coordenadas exactas. Deben definirse retención, acceso, eliminación y respuesta ante filtraciones.
7. **Financiar el ciclo de retroalimentación.** Recoger casos difíciles sin personal que los revise crea una cola, no un dataset. El presupuesto debe incluir validación, curación, deduplicación, versionado y reentrenamiento, además del desarrollo de la aplicación.
8. **Exigir validación de campo antes del uso masivo.** Una versión candidata debe aprobar criterios predefinidos de rendimiento por clase y entorno, prueba de teléfonos, estabilidad offline y comprensión del mensaje de incertidumbre. Una caída grande en potasio o en una región debe detener la promoción aunque el accuracy global siga alto.
9. **Publicar una ficha de cada versión.** La ficha debe incluir corpus, fingerprint, clases, protocolo, métricas por grupo, limitaciones, hash del modelo y cambios desde la versión anterior, siguiendo la idea de reportes de modelo [4]. Esto permite saber qué produjo un diagnóstico meses después.

Estas recomendaciones colocan el mayor esfuerzo donde el experimento encontró la mayor fragilidad: datos con contexto, revisión y seguimiento. Comprar más capacidad de cómputo puede facilitar el entrenamiento, pero no resuelve una etiqueta ambigua ni una región ausente. La política útil conecta el modelo con una red de asistencia y con reglas para corregirlo.

16. Limitaciones

1. **No hubo ajuste fino end-to-end en la corrida nueva.** La máquina disponible no expuso CUDA. Se compararon backbones ImageNet congelados con una cabeza logística optimizada. Es un experimento completo sobre el corpus, pero no demuestra el rendimiento que tendrían las mismas arquitecturas al adaptar todos sus pesos.
2. **La comparación con Etapa 1 no es controlada.** Cambiaron corpus, división, objetivo de entrenamiento y familia de cabeza. Las diferencias históricas ayudan a entender el proyecto; no aíslan el efecto causal de la ampliación o de Optuna.
3. **Los grupos de entorno están confundidos con la clase.** Solamente roya, mancha gris y tizón norteño tienen imágenes tanto de laboratorio como de campo. El gap global resume el dataset, no mide por sí solo el efecto de retirar un fondo uniforme.
4. **Faltan metadatos de campo.** No se conoce finca, municipio, variedad, teléfono, campaña o evaluador. La fuente del archivo no reemplaza esos datos y puede estar asociada simultáneamente con clase, resolución y estilo de captura.
5. **Blur y resolución son indicadores indirectos.** La varianza del Laplaciano depende del con-

tenido de la lesión y la compresión, no solamente del enfoque. Los terciles describen diferencias internas y no fijan un umbral universal de calidad.

6. **La validación cruzada es condicional a una selección previa.** Arquitectura, hiperparámetros y ensemble se eligieron con la división train/validación. Los cinco folds posteriores miden estabilidad dentro del desarrollo; el estimador verdaderamente no consultado es el holdout final.
7. **No se calibraron probabilidades.** La confianza sirve para ordenar alternativas y activar una advertencia de interfaz, pero no se comprobó confiabilidad mediante ECE, diagrama de calibración o temperatura ajustada en un conjunto separado.
8. **La explicación del ensemble es aproximada.** Grad-CAM combina mapas normalizados de componentes usando los pesos de soft voting. Esto ayuda a localizar regiones influyentes, pero no produce una descomposición causal exacta de la probabilidad conjunta. LIME usa 32 perturbaciones en un caso y explica solo EfficientNet-B0, el componente de mayor peso.
9. **La latencia no es móvil.** Los valores comparativos de backbones y la demo corresponden a CPU de escritorio. El artefacto móvil histórico sí está integrado, pero no se ejecutó un benchmark en varios teléfonos Android durante esta etapa.
10. **Disponibilidad pública no confirmada al cierre.** La aplicación aprobó typecheck y 276 pruebas, pero el dominio de la API dejó de resolver en la comprobación final y la URL de APK respondió 404 sin autenticación. No se otorgan todos los puntos de despliegue.
11. **Cobertura diagnóstica limitada.** Nueve etiquetas no representan todas las enfermedades, plagas, daños químicos, estrés hídrico ni síntomas mixtos. El sistema no determina dosis, causalidad ni manejo a partir de una sola foto.
12. **No hay validación prospectiva salvadoreña ni medición de impacto.** Los resultados provienen de colecciones públicas. No se midió concordancia con especialistas en parcelas, ahorro, rendimiento, adopción o comprensión del usuario.

Ninguna de estas limitaciones invalida los artefactos generados. Define con precisión qué pregunta respondieron. La etapa demuestra un protocolo de selección reproducible y una ruta funcional de producto; todavía no demuestra eficacia agronómica ni disponibilidad operativa a escala.

17. Conclusiones

La Etapa 1 terminó con tres buenos baselines y una pregunta incómoda: ¿de qué sirve superar 0.90 de macro-F1 si potasio sigue fallando y el test ya fue visto varias veces? La segunda etapa no resolvió ese problema con una sola cifra. Cambió el corpus, congeló un holdout nuevo, comparó representaciones bajo el mismo protocolo y mantuvo las métricas minoritarias junto al resultado global.

El tuning produjo la mejora controlada más clara del trabajo. Sobre EfficientNet-B0 y la misma validación, la cabeza pasó de 0.7799 a 0.8887 de macro-F1. El cambio que más importó no fue añadir parámetros: fue reducir la tasa, usar penalización L2 y ponderar las clases con la raíz de su frecuencia inversa. Recall macro aumentó 0.1399. Esto confirma que el baseline dejaba información útil en los embeddings, pero la frontera aprendida favorecía a las clases grandes.

EfficientNet-B0 volvió a ser el mejor modelo individual, aunque no dominó cada imagen. Su conjunto de errores tuvo Jaccard 0.277 con MobileNetV3; esa complementariedad permitió que el voto ponderado alcanzara 0.9202 en validación, 0.0315 más que B0. El costo es concreto: cuatro

backbones, cerca de 38.3 MB FP32 sumados y más latencia. Para investigación se selecciona el ensemble; para teléfono, ShuffleNet o MobileNet siguen siendo alternativas que merecen una prueba de dispositivo.

Los cinco folds situaron el macro-F1 en 0.9097 ± 0.0090 . El holdout único quedó en 0.9035, acompañado por 0.9537 de accuracy. La cercanía con validación cruzada indica que la selección no dependió completamente de un corte, pero el quinto fold reveló su límite: potasio cayó a F1 0.6304. En el holdout, potasio obtuvo 0.6706 y solo 57 de 93 imágenes correctas. Veintiocho de sus 36 errores fueron nitrógeno. La clase mejoró frente a la referencia histórica de 0.62, pero sigue siendo el problema central y no debe ocultarse detrás de 95 % de accuracy.

El sesgo laboratorio/campo resultó más específico de lo que sugería un promedio global. Mancha gris y tizón tuvieron recalls ligeramente mayores en campo; roya pasó de 1.0 en 322 imágenes de laboratorio a 0.3125 en 16 de campo. El soporte pequeño impide fijar la magnitud real, pero la dirección confirma que el fondo controlado puede sostener un atajo. Las brechas por fuente y clase fueron mayores que las de resolución. La acción correcta no es declarar que el modelo es justo, sino recolectar roya de campo, revisar N/P/K y monitorear cada segmento con su soporte.

La aplicación móvil completa la cadena técnica: captura, preprocesamiento, TFLite local, confianza, OOD, resultado e historial offline. Sus 276 pruebas y typecheck aprobaron; la demo experimental también produjo una salida real. Sin embargo, el modelo final de esta etapa no reemplazó el EfficientNet-Lite0 embarcado y el despliegue público no estuvo accesible al cierre. El informe descuenta esa evidencia faltante. Un prototipo funcional no se convierte en servicio disponible solamente porque exista una URL en la configuración.

17.1. Cumplimiento de la rúbrica

La calificación documentada es 96/100. Los cuatro puntos no otorgados corresponden al criterio de prototipo: faltó comprobar disponibilidad pública continua y ejecutar el modelo experimental final dentro de Android. Los demás criterios poseen CSV, JSON, código, figuras y secciones enlazadas. No se asignó puntaje por una capacidad registrada sin corrida.

Doctor Maíz queda en un punto útil pero delimitado. Ya existe evidencia reproducible de selección y una aplicación donde integrar modelos; todavía falta la evidencia que solo puede dar el campo. La siguiente decisión no debería buscar otra arquitectura por novedad, sino comprobar con productores y extensionistas si las hojas locales, los teléfonos reales y la forma de mostrar incertidumbre sostienen lo observado aquí.

Cuadro 12: Puntuación final respaldada por artefactos reproducibles.

Criterio	Puntos	Estado	Evidencia
Optimización e hiperparámetros	20/20	Completo	30 trials, 13 podados; macro-F1 0.7799 a 0.8887.
Modelos avanzados y ensemble	20/20	Completo	Cuatro backbones; weighted soft voting mejora 0.0315.
Evaluación rigurosa	15/15	Completo	5-fold y holdout congelado evaluado una sola vez.
Sesgos y ética	15/15	Completo	Brechas por clase, entorno, fuente, blur y resolución.
Prototipo	11/15	Parcial	Demo y 276 pruebas; API/APK no disponibles al cierre.
Impacto y recomendaciones	15/15	Completo	Condiciones de uso y nueve propuestas concretas.
TOTAL	96/100	Cumplimiento con una salvedad	La disponibilidad pública del despliegue no pudo confirmarse al cierre.

Referencias

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.
- [2] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, and Hartwig Adam. Searching for mobilenetv3. In *2019 IEEE/CVF International Conference on Computer Vision*, pages 1314–1324, 2019. doi: 10.1109/ICCV.2019.00140.
- [3] Ningning Ma, Xiangyu Zhang, Hai-Tao Zheng, and Jian Sun. Shufflenet v2: Practical guidelines for efficient cnn architecture design. In *European Conference on Computer Vision*, pages 116–131, 2018.
- [4] Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, and Timnit Gebru. Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency*, pages 220–229, 2019. doi: 10.1145/3287560.3287596.
- [5] Proyecto Doctor Maíz. Maize disease and deficiency dataset. Hugging Face Datasets, 2026. URL <https://huggingface.co/datasets/elmerrosales/maize-disease-deficiency-dataset>. Consultado el 9 de septiembre de 2026.
- [6] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. Why should i trust you? explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016. doi: 10.1145/2939672.2939778.
- [7] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *2017 IEEE International Conference on Computer Vision*, pages 618–626, 2017. doi: 10.1109/ICCV.2017.74.
- [8] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, pages 6105–6114, 2019.
- [9] Pavan Kumar Anasosalu Vasu, James Gabriel, Jeff Zhu, Oncel Tuzel, and Anurag Ranjan. Fastvit: A fast hybrid vision transformer using structural reparameterization. In *2023 IEEE/CVF International Conference on Computer Vision*, pages 5785–5795, 2023.